

2021 Spring

# Artificial Intelligence & Deep Learning

Prof. Minsuk Koo


Department of Computer Science &  
Engineering  
Incheon National University




## 6.1 지도 학습과 비지도 학습, 준지도 학습

### ■ 세 가지 유형의 학습


- 지도 학습: 모든 훈련 샘플이 레이블 정보를 가짐
- 비지도 학습: 모든 훈련 샘플이 레이블 정보를 가지지 않음 ← 6장의 주제
- 준지도 학습: 레이블을 가진 샘플과 가지지 않은 샘플이 섞여 있음 ← 7장의 주제



(a) 지도 학습



(b) 비지도 학습



(c) 준지도 학습

그림 6-1 기계 학습의 유형(속이 찬 샘플은 레이블이 있고, x 표시된 샘플은 레이블이 없음)

## 6.1 지도 학습과 비지도 학습, 준지도 학습

### ■ 기계 학습이 사용하는 두 종류의 지식

- 훈련집합
- 사전 지식 prior knowledge (세상의 일반적인 규칙)

### ■ 중요한 두 가지 사전 지식

데이터가 낮은 차원으로 표현할 수 있다. 라는 가정

- 매니폴드 가정 manifold hypothesis: 데이터집합은 하나의 매니폴드 또는 여러 개의 매니폴드를 구성하며, 모든 샘플은 매니폴드와 가까운 곳에 있다. 매니폴드와 매니폴드 가정은 6.8.1절에서 자세히 설명한다.
- 매끄러움 가정 smoothness hypothesis: 샘플은 어떤 요인에 의해 변화한다. 예를 들어, 장면과 카메라 위치를 고정한 상태에서 조명을 조금씩 변화하면서 영상을 획득한 경우, 획득된 영상 샘플은 특징 공간에서 위치가 조금씩 바뀔 것이다. 이때 [그림 6-1(b)]와 같이 매끄러운 곡면을 따라 위치가 변한다.

### ■ 비지도 학습과 준지도 학습은 사전 지식을 더 명시적으로 사용

## 6.2 비지도 학습

---

- 6.2.1 비지도 학습의 일반 과업
- 6.2.2 비지도 학습의 응용 과업

## 6.2.1 비지도 학습의 일반 과업

### ■ 세 가지 일반 과업

- **군집화**: 유사한 샘플을 모아 같은 그룹으로 묶는 일
- **밀도 추정**: 데이터로부터 확률분포를 추정하는 일
- **공간 변환**: 원래 특징 공간을 저차원 또는 고차원 공간으로 변환하는 일

■ 데이터에 내재한 구조를 잘 파악하여 새로운 정보를 발견해야 함




그림 6-2 비지도 학습의 군집화, 밀도 추정, 공간 변환 과업이 발견하는 정보

## 6.2.2 비지도 학습의 응용 과업

### ■ 아주 많은 응용(서로 밀접하게 연관)

#### ■ 군집화의 응용

- 맞춤 광고, 영상 분할, 유전자 데이터 분석, SNS 실시간 검색어 분석하여 사람들의 관심 파악 등

#### ■ 밀도 추정의 응용

- 분류, 생성 모델 구축 등

#### ■ 공간 변환의 응용

- 데이터 가시화, 데이터 압축, 특징 추출(표현 학습) 등

## 6.3 군집화

- 6.3.1 k-평균 알고리즘 *k-means*
- 6.3.2 친밀도 전파 알고리즘

## 6.3 군집화

### ■ 군집화 문제

- $\mathbb{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ 에서 식 (6.1)을 만족하는 군집집합  $C = \{c_1, c_2, \dots, c_k\}$ 를 찾아내는 작업

$$\left. \begin{array}{l} c_i \neq \emptyset, i = 1, 2, \dots, k \\ \bigcup_{i=1}^k c_i = \mathbb{X} \\ c_i \cap c_j = \emptyset, i \neq j \end{array} \right\} \quad (6.1)$$

- 군집의 개수  $k$ 는 주어지는 경우와 자동으로 찾아야 하는 경우가 있음
- 군집화를 부류 발견 작업이라 부르기도 함

*k-means : k정해줘야함*  
*친밀도 : k가 주어짐*

### ■ 군집화의 주관성




그림 6-3 군집화의 주관성



## 6.3.1 $k$ -평균 알고리즘

### ■ $k$ -평균 알고리즘의 특성

- 원리 단순하지만 성능이 좋아 인기 좋음
- 직관적으로 이해하기 쉽고 구현 쉬움
- 군집 개수  $k$ 를 알려줘야 함

#### 알고리즘 6-1 $k$ -평균

입력: 훈련집합  $\mathbb{X} = \{x_1, x_2, \dots, x_n\}$ , 군집의 개수  $k$

출력: 군집집합  $C = \{c_1, c_2, \dots, c_k\}$

```
1   $k$ 개의 군집 중심  $Z = \{z_1, z_2, \dots, z_k\}$ 를 초기화한다.
2  while (true)
3      for ( $i=1$  to  $n$ )
4           $x_i$ 를 가장 가까운 군집 중심에 배정한다.  $\leadsto$  유클리디안 거리
5          if (라인 3~4에서 이루어진 배정이 이전 루프에서의 배정과 같으면) break
6          for ( $j=1$  to  $k$ )
7               $z_j$ 에 배정된 샘플의 평균으로  $z_j$ 를 대체한다.  $\leadsto$  새로운 대표값
8          for ( $j=1$  to  $k$ )
9               $z_j$ 에 배정된 샘플을  $c_j$ 에 대입한다.
```

## 6.3.1 $k$ -평균 알고리즘

### ■ $k$ -평균과 $k$ -medoids

- $k$ -평균은 [알고리즘 6-1]의 라인 7에서 샘플의 평균으로 군집 중심을 갱신
- $k$ -medoids는 대표를 뽑아 뽑힌 대표로 군집 중심을 갱신( $k$ -평균에 비해 잡음에 둔감)

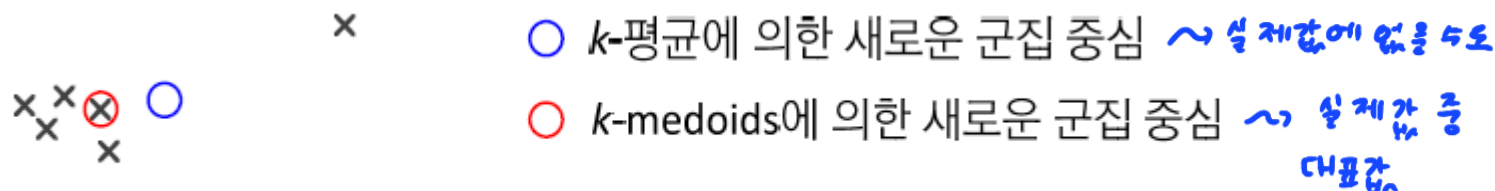


그림 6-4  $k$ -평균과  $k$ -medoids가 군집 중심을 갱신하는 과정

### ■ 최적화 문제로 해석

- $k$ -평균은 식 (6.2)의 목적함수를 최소화하는 알고리즘
- 행렬  $\mathbf{A}$ 는 군집 배정 정보를 나타내는  $k \times n$  행렬( $i$ 번째 샘플이  $j$ 번째 군집에 배정되었다면  $a_{ji}$ 는 1, 그렇지 않으면 0)

$$J(\mathbf{Z}, \mathbf{A}) = \sum_{i=1}^n \sum_{j=1}^k a_{ji} \text{dist}(\mathbf{x}_i, \mathbf{z}_j) \quad (6.2)$$

$\hookrightarrow$  데이터가 어디에 포함 되어 있는지 (one hot code)

## 6.3.1 $k$ -평균 알고리즘

### 예제 6-1 $k$ -평균의 동작

[그림 6-5]는 훈련집합이 7개의 샘플을 가진  $n=7$ 인 예를 보여 준다. 좌표는 다음과 같다.

$$\mathbf{x}_1 = \begin{pmatrix} 18 \\ 5 \end{pmatrix}, \mathbf{x}_2 = \begin{pmatrix} 20 \\ 9 \end{pmatrix}, \mathbf{x}_3 = \begin{pmatrix} 20 \\ 14 \end{pmatrix}, \mathbf{x}_4 = \begin{pmatrix} 20 \\ 17 \end{pmatrix}, \mathbf{x}_5 = \begin{pmatrix} 5 \\ 15 \end{pmatrix}, \mathbf{x}_6 = \begin{pmatrix} 9 \\ 15 \end{pmatrix}, \mathbf{x}_7 = \begin{pmatrix} 6 \\ 20 \end{pmatrix}$$

군집의 개수  $k=3$ 이라 하자. 맨 왼쪽 그림은 초기 군집 중심을 보여 준다. [알고리즘 6-1]의 라인 3~4는 7개 샘플을 아래와 같이 배정할 것이다.

$$\{\mathbf{x}_1\} \text{은 } \mathbf{z}_1, \{\mathbf{x}_2\} \text{은 } \mathbf{z}_2, \{\mathbf{x}_3, \mathbf{x}_4, \mathbf{x}_5, \mathbf{x}_6, \mathbf{x}_7\} \text{은 } \mathbf{z}_3$$

이 배정을 행렬  $\mathbf{A}$ 로 표현하면 다음과 같다.

$$\mathbf{A} = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 1 & 1 & 1 & 1 \end{pmatrix}$$

## 6.3.1 $k$ -평균 알고리즘

[그림 6-5]의 가운데 그림은 새로 계산한 군집 중심이다.  $z_1 = (18, 5)^T$ ,  $z_2 = (20, 9)^T$ ,  $z_3 = (12, 16.2)^T$  이고, 식 (6.2)에 대입하면  $J = 33.77$  이 된다. 이때 거리함수 dist로 식 (1.7)의 유클리디언 거리를 사용한다.

두 번째 루프를 실행하면 행렬  $A$ 는 아래와 같이 바뀐다. 군집 중심은  $z_1 = (18, 5)^T$ ,  $z_2 = (20, 13.333)^T$ ,  $z_3 = (6.667, 16.667)^T$ 이다. 이것을 식 (6.2)에 대입하면  $J = 17.29$  이 된다. [그림 6-5]의 맨 오른쪽 그림은 두 번째 루프 수행 후의 상황이다.

$$A = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 1 & 1 \end{pmatrix}$$

첫 번째 군집  
 두 번째 ' '  
 세 번째 ' '




그림 6-5  $k$ -평균의 동작 예제

## 6.3.1 $k$ -평균 알고리즘

### ■ 다중 시작 $k$ -평균

- $k$ -평균은 [알고리즘 6-1]의 라인 1에서 초기 군집 중심이 달라지면 최종 결과가 달라짐
- 다중 시작은 서로 다른 초기 군집 중심을 가지고 여러 번 수행한 다음, 가장 좋은 품질의 해를 취함

#### 알고리즘 6-2 다중 시작 $k$ -평균

입력: 훈련집합  $X = \{x_1, x_2, \dots, x_n\}$ , 군집의 개수  $k$ , 다중 시작 횟수  $t$

출력: 군집집합  $C = \{c_1, c_2, \dots, c_k\}$

```
1 for ( $i=1$  to  $t$ )
2      $X$ 에서 임의로  $k$ 개 샘플을 뽑는다.
3     라인 2에서 뽑은 샘플을 초기 군집 중심으로 삼고, [알고리즘 6-1]의  $k$ -평균을 수행한다.
4      $k$ -평균이 출력한 해를 가지고 식 (6.2)의 목적함숫값을 계산한다.
5      $t$ 개의 해 중 목적함숫값이 가장 작은 해를 최종해로 취한다.
```

## 6.3.1 $k$ -평균 알고리즘

### ■ EM 기초

- $k$ -평균에서 훈련집합  $\mathbb{X}$ 와 군집집합  $C$ (행렬  $A$ )는 각각 입력단과 출력단에서 관찰 가능
- 중간 단계의 입시 변수  $Z$ (입출력단에서 보이지 않기 때문에 은닉변수라<sup>latent variable</sup> 부름)
- $k$ -평균은  $Z$ 의 추정(E 단계)과  $A$ 의 추정(M 단계)을 번갈아 가면 수행하는 EM 알고리즘

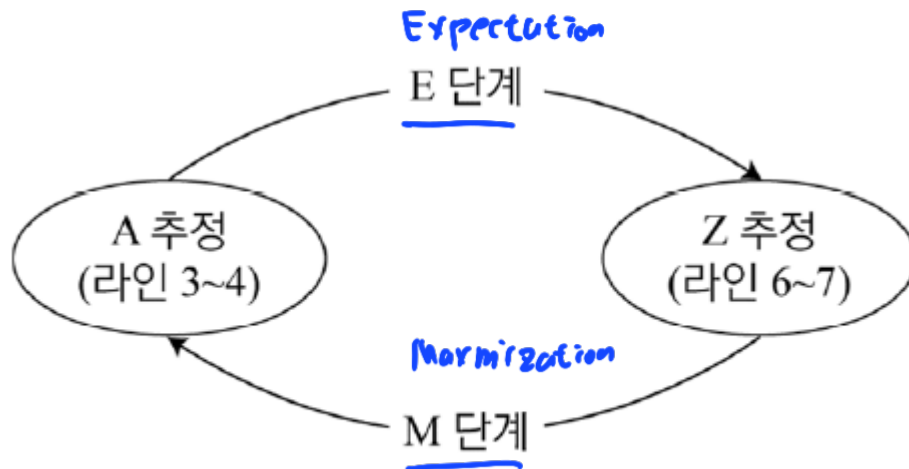


그림 6-6  $k$ -평균을 EM 알고리즘으로 해석

## 6.3.2 친밀도 전파 알고리즘

### ■ 친밀도 전파 알고리즘

- 책임 행렬  $\mathbf{R}$ 과 가용 행렬  $\mathbf{A}$ 라는 두 종류의 친밀도 행렬을 이용하여 군집화
- 군집 개수  $k$ 를 자동으로 알아냄

### ■ 샘플 $i$ 와 $k$ 의 유사도 $s_{ik}$

$$s_{ik} = -\|\mathbf{x}_i - \mathbf{x}_k\|_2^2, \quad i \neq k \text{이고 } i, k = 1, 2, \dots, n \quad (6.3)$$


$\hookrightarrow$  - Euclidean distance

## 6.3.2 친밀도 전파 알고리즘


### ■ 책임 행렬 **R**과 가용 행렬 **A**의 계산

$$r_{ik} = s_{ik} - \max_{k' \neq k} (a_{ik'} + s_{ik'}) \quad (6.4)$$

$$\underline{a_{ik}} = \min \left( 0, r_{kk} + \sum_{i' \neq i, k} \max(0, r_{i'k}) \right), i \neq k \quad (6.5)$$



(a)  $r_{ik}$ 의 계산 (비교)



(b)  $a_{ik}$ 의 계산 (비교)

그림 6-7 친밀도 계산 과정



## 6.3.2 친밀도 전파 알고리즘

### ■ 자가 유사도 $s_{kk}$

- 유사도의 최솟값, 중앙값(메디안), 최댓값 중에서 선택(하이퍼 매개변수임)
- 최솟값은 적은 수의 군집, 최댓값은 많은 수의 군집을 생성. 중앙값은 중간 정도

### ■ 자가 친밀도 $r_{kk}$ 와 $a_{kk}$

- $r_{kk}$ 는 식 (6.4)를 그대로 사용. 즉
- $a_{kk}$ 는 식 (6.6)으로 계산

$$r_{kk} = s_{kk} - \max_{k' \neq k} (a_{kk'} + s_{kk'})$$

$$a_{kk} = \sum_{i' \neq k} \max(0, r_{i'k}) \quad (6.6)$$

## 6.3.2 친밀도 전파 알고리즘

### 알고리즘 6-3 친밀도 전파 군집화

입력: 훈련집합  $\mathbb{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ , 군집 개수 선택사항  $\in \{\text{최솟값}, \text{메디안}, \text{최댓값}\}$ , **댐핑 인자  $\lambda$**   
 출력: 군집 정보  $\mathbf{z} = (z_1, z_2, \dots, z_n)^T$

```

1 for (모든 샘플 쌍  $i$ 와  $k$ 에 대해) if ( $i \neq k$ )  $s_{ik} = -\|\mathbf{x}_i - \mathbf{x}_k\|_2^2$  // 식 (6.3)
2 for ( $k = 1$  to  $n$ )  $s_{kk}$  = 선택 사항에 따라 라인 1의 유사도의 최솟값, 중앙값, 또는 최댓값
3 for (모든 샘플 쌍  $i$ 와  $k$ 에 대해)  $a_{ik}^0 = 0, r_{ik}^0 = 0$ 
4  $t = 0$   $A = 0 \quad R = 0$ 
```

라인 9&13은 진자 현상을  
방지하기 위해 댐핑 인자 적용

```

5 repeat
6      $t++$ 
7     for (모든 샘플 쌍  $i$ 와  $k$ 에 대해)
8          $r_{ik}^t = s_{ik} - \max_{k' \neq k} (a_{ik'}^t + s_{ik'})$  // 식 (6.4)
9          $r_{ik}^t = \lambda r_{ik}^t + (1 - \lambda) r_{ik}^{t-1}$ 
10    for (모든 샘플 쌍  $i$ 와  $k$ 에 대해)
11        if ( $i \neq k$ )  $a_{ik}^t = \min(0, r_{kk}^t + \sum_{i' \neq i, k} \max(0, r_{i'k}^t))$  // 식 (6.5)
12        else  $a_{kk}^t = \sum_{i' \neq k} \max(0, r_{i'k}^t)$  // 식 (6.6)
13         $a_{ik}^t = \lambda a_{ik}^t + (1 - \lambda) a_{ik}^{t-1}$ 
14 until (멈춤 조건)
15 for ( $i = 1$  to  $n$ )
16      $\hat{k} = \operatorname{argmax}_{k=1, n} (a_{ik}^t + r_{ik}^t)$ 
17     if ( $\hat{k} = i$ )  $z_i = i$  // 이 샘플은 군집 중심임
18     else  $z_i = \hat{k}$  // 이 샘플은  $\hat{k}$  군집 중심에 속함
```

← 자신의 자가 친밀도가 최고이면 군집 대표

## 6.4 밀도 추정

- 6.4.1 커널 밀도 추정
- 6.4.2 가우시안 혼합
- 6.4.3 EM 알고리즘

- 밀도 추정 문제

- 어떤 점  $\mathbf{x}$ 에서 데이터가 발생할 확률, 즉 확률 분포  $P(\mathbf{x})$ 를 구하는 문제
- 예를 들어, 그림 6-8에서  $P(\mathbf{x}_1) > P(\mathbf{x}_2) > P(\mathbf{x}_3)$




그림 6-8 밀도 추정 문제