Predicting stock prices based on people's reactions.

201600779 김영민

Context

01 Introduce My Project

02 Interim findings

03 Method of Data Collection

04 Next Process

Motivation

여론 속의 여론

주식 투자자 43% "코로나 이후 시작"… 92% "계속할 것"

입력 2021.05.06 04:30

주식 직접투자 행태 및 투자자산 인식 조사

〈그림 1〉 개인투자자 거래규모

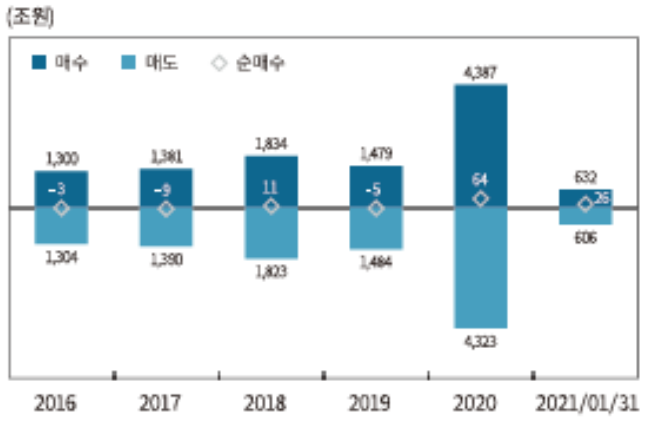

코로나 이후 개인 투자자 비율

Then

사람들의 기대 심리가 주가에 영향을 미칠까???

개인들이 가장 많이 접하게 되는 회사 소식인 기사들에 의해 주가 변동에 영향이 있을까?

Introduce My Project

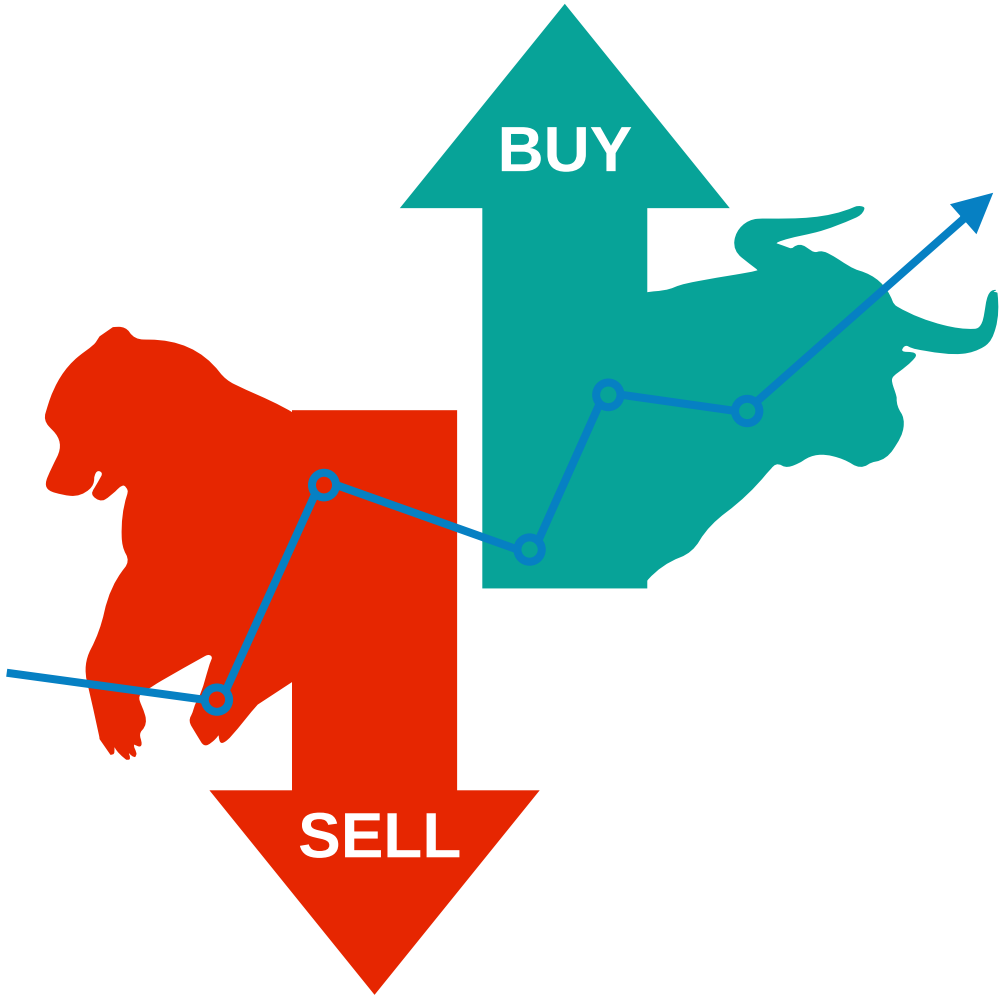

Is Individual reaction related to stock prices?

종목

- ❖ 삼성전자
- ❖ 네이버
- ❖ 셀트리온
- ❖ 기업은행

기간

- ❖ 2021.01~2021.10.15
- ❖ Test는 2021.11월 주가로 시행

수집 데이터

- ❖ Investing.com의 여론 데이터
- ❖ 네이버 기사 데이터
- ❖ 시작가와 종가 데이터

Prediction Model

- ❖ RandomForest Classification
- ❖ LGBM Classification
- ❖ LSTM or GRU

Semantic Analysis

- ❖ KNU 감정사전
- ❖ VADER
- ❖ Google Cloud API

발전 방향

- ❖ 코로나 전후 1년 비교
- ❖ 딥러닝을 활용한 감정 분석
- ❖ 여러 사이트를 활용한 감정 분석

Interim findings

Investing.com Crawling

각 주가에 대한 사람들의 상승 하락 여론 데이터 수집

Collect Stock Price

시작가 종가에 대한 데이터 수집

Collect Good news or Bad news

주가 상승과 하락에 영향을 끼치는 뉴스 데이터 크롤링

Investing.com Opinion

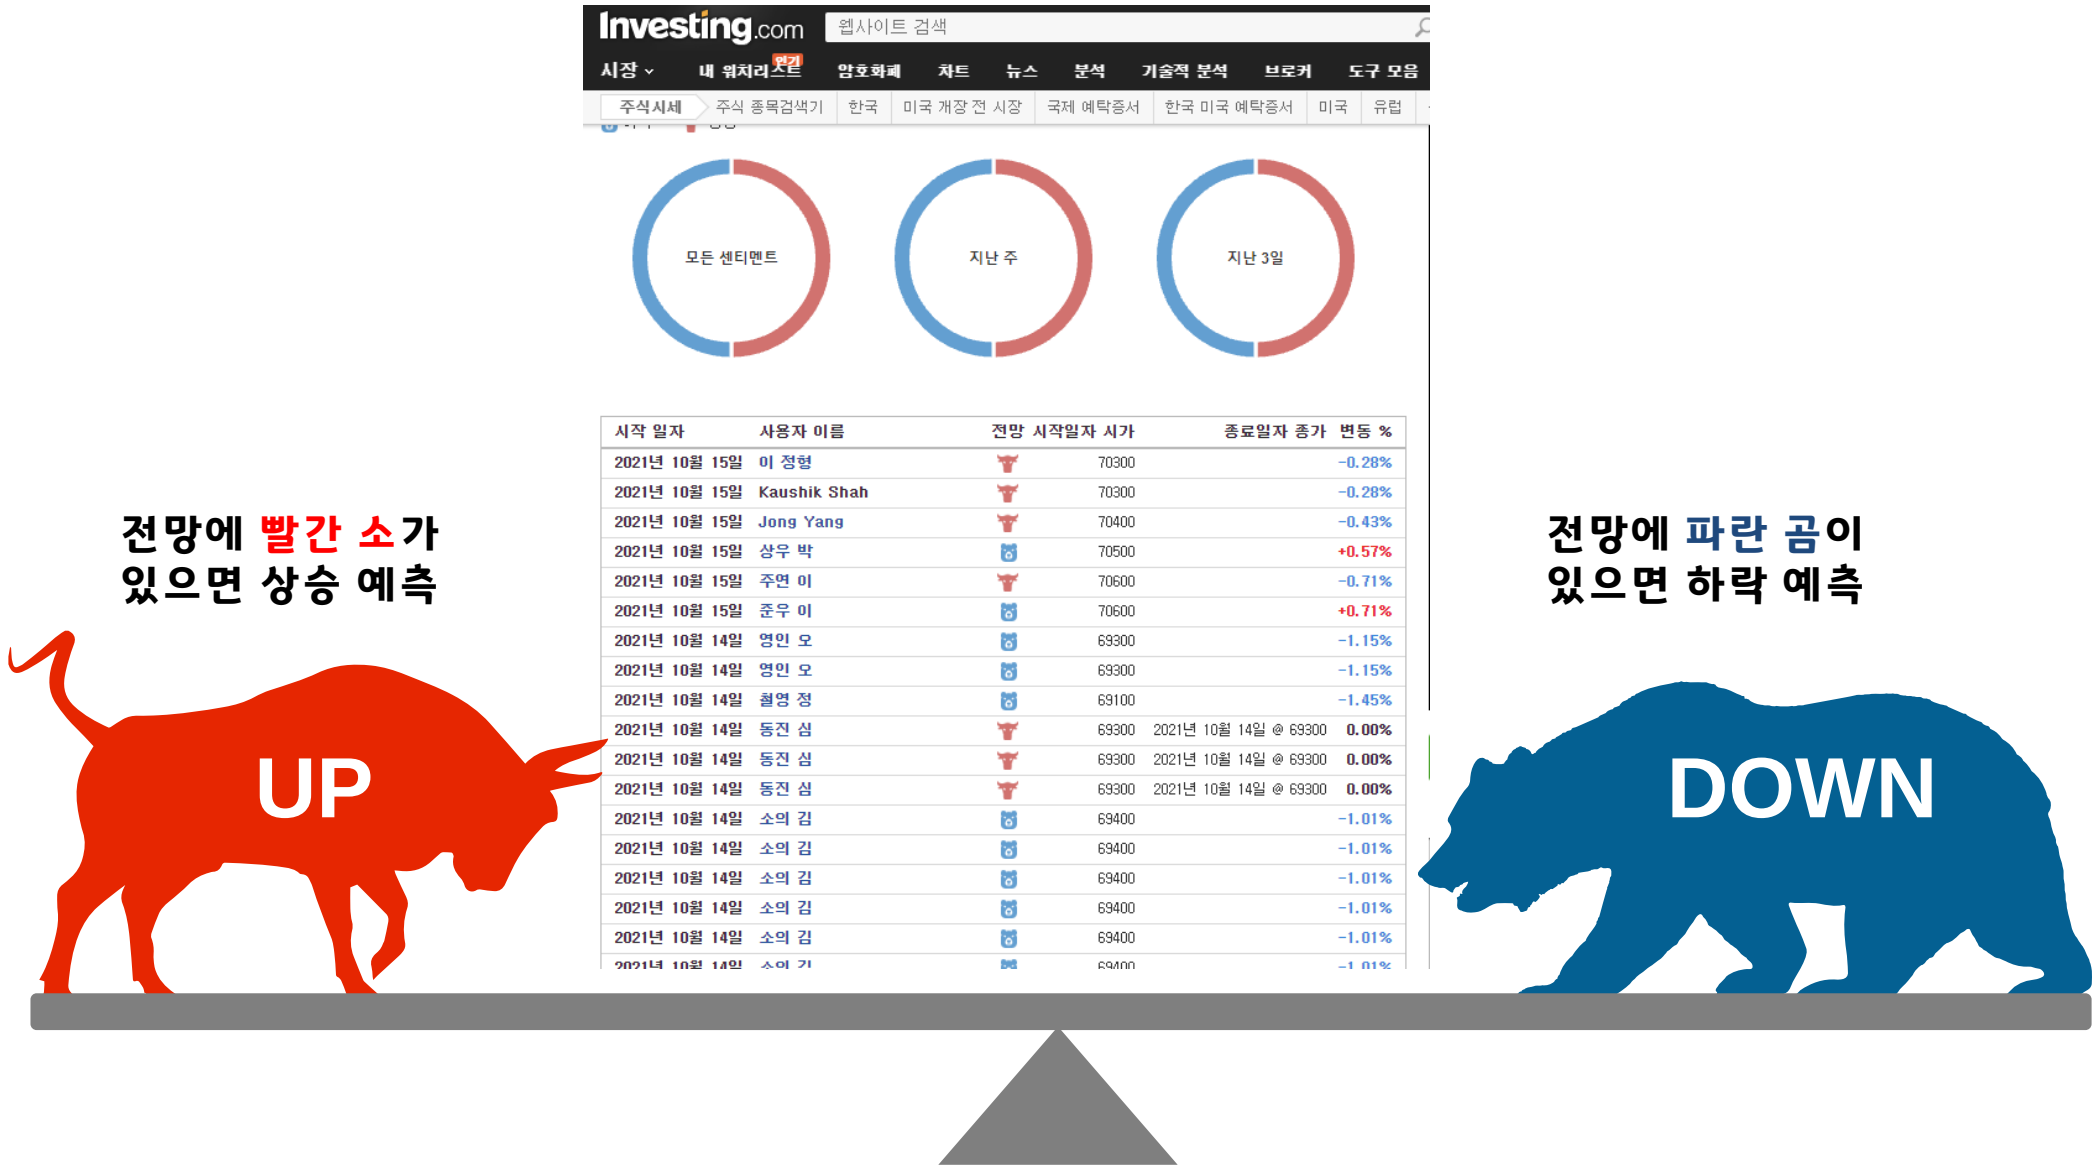

전망에 빨간 소가 있으면 상승 예측

전망에 파란 곰이 있으면 하락 예측

Crawling

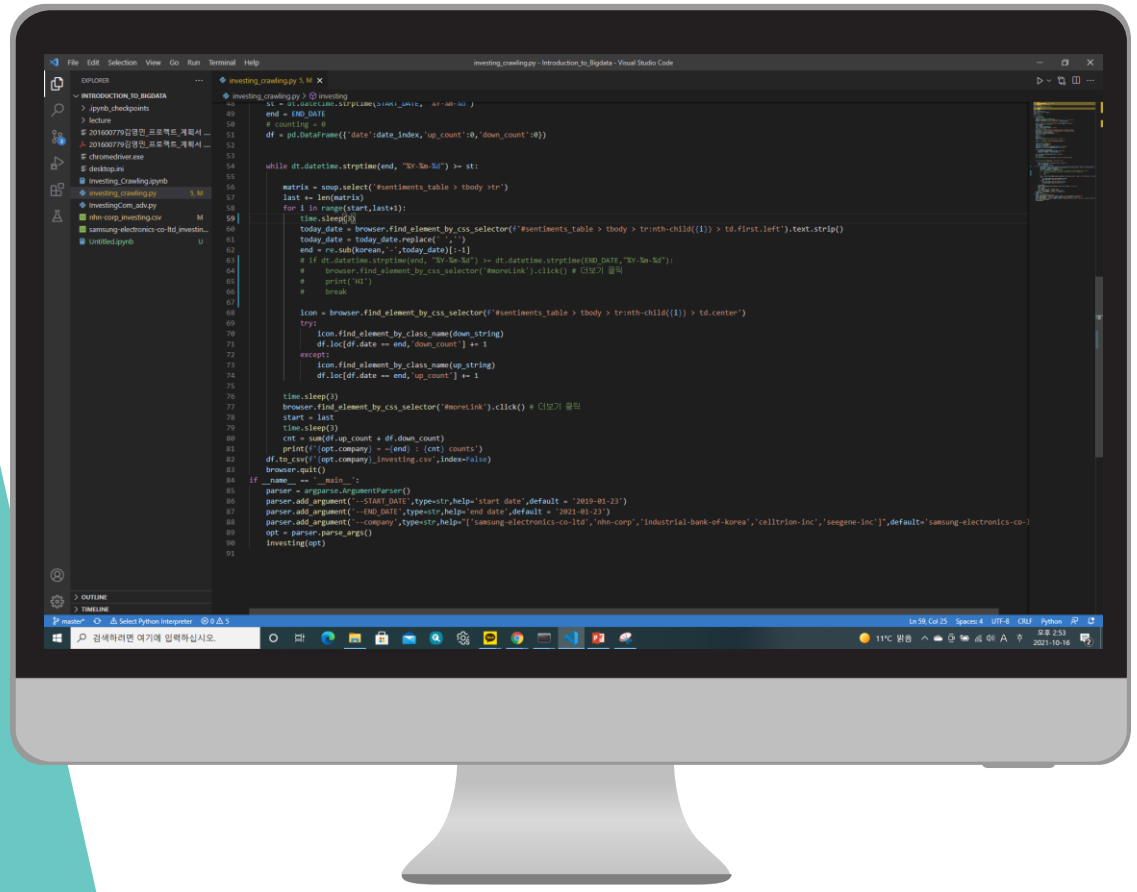

Selenium

일반 BeautifulSoup 로는 접근이 불가능 하기 때문에 Selenium을 이용하여 사이트 접근

BeautifulSoup

BeautifulSoup를 사용하여 원하는 정보 추출

https://github.com/winston1214/INU/blob/master/Introduction_to_Bigdata/investing_crawling.py

Stock Price

주가 데이터 다운로드

005930 역사적 데이터

기간:
일간

데이터 다운로드 | 2021/09/16 - 2021/10/16

날짜	종가	오픈	고가	저가	거래량	변동 %
2021년 10월 15일	70,100	70,200	71,000	70,000	17.53M	1.01%
2021년 10월 14일	69,400	69,100	69,800	68,800	0.23K	0.87%
2021년 10월 13일	68,800	68,700	69,600	68,400	0.57K	-0.29%
2021년 10월 12일	69,000	70,800	70,900	68,700	18.42K	-3.50%
2021년 10월 11일	71,500	71,500	71,500	71,500	-	0.00%
2021년 10월 08일	71,500	72,300	72,400	71,500	13.97M	-0.14%
2021년 10월 07일	71,600	71,800	72,100	71,300	0.17K	0.42%
2021년 10월 06일	71,300	72,700	72,800	71,200	8.34K	-1.25%
2021년 10월 05일	72,200	72,900	73,000	71,400	1.12K	-1.37%
2021년 10월 04일	73,200	73,200	73,200	73,200	-	0.00%
2021년 10월 01일	73,200	73,900	74,000	72,900	15.70M	-1.21%
2021년 09월 30일	74,100	74,300	74,800	73,800	6.44K	0.00%
2021년 09월 29일	74,100	74,800	75,300	73,800	15.27K	-2.88%
2021년 09월 28일	76,300	77,600	77,600	76,200	0.94K	-1.80%
2021년 09월 27일	77,700	77,300	77,700	77,000	11.63M	0.52%
2021년 09월 26일	77,300	77,300	77,300	77,300	-	0.00%
2021년 09월 24일	77,300	77,600	77,700	77,100	11.85M	-0.13%
2021년 09월 23일	77,400	77,500	77,600	76,900	0.49K	0.26%
2021년 09월 22일	77,200	77,200	77,200	77,200	-	0.00%
2021년 09월 17일	77,200	76,300	77,200	75,900	15.66M	1.45%
2021년 09월 16일	76,100	77,300	77,400	76,100	12.88M	-1.17%

최고: 77,700 | 최저: 68,400 | 차이: 9,300 | 평균: 73,643 | 변동 %: -9

By investing.com

데이터 다운로드가 한 달 단위로 제공되기 때문에 데이터 결합 필요


```
import pandas as pd
import os
ls = os.listdir('samsung')
df_list = []
for i in ls:
    data = pd.read_csv('samsung/'+i)
    df_list.append(data)
df = pd.concat(df_list).reset_index(drop=True)
```

	날짜	종가	오픈	고가	저가	거래량	변동 %
0	2021년 02월 26일	82,500	82,800	83,400	82,000	36.72M	-3.28%
1	2021년 02월 25일	85,300	84,000	85,400	83,000	6.35K	4.02%
2	2021년 02월 24일	82,000	81,900	83,600	81,400	0.98K	0.00%
3	2021년 02월 23일	82,000	81,300	82,900	81,100	7.03K	-0.24%
4	2021년 02월 22일	82,200	83,800	84,200	82,200	17.48K	-0.48%
...	...	...	...	...	...	...	...
230	2021년 09월 06일	77,300	76,800	77,600	76,600	3.42K	0.91%
231	2021년 09월 05일	76,600	76,600	76,600	76,600	-	0.00%
232	2021년 09월 03일	76,600	76,400	76,700	76,000	11.89M	0.79%
233	2021년 09월 02일	76,000	76,800	76,800	75,700	1.76K	-1.04%
234	2021년 09월 01일	76,800	76,600	77,100	75,900	0.84K	0.13%

235 rows × 7 columns

Naver News Crawling

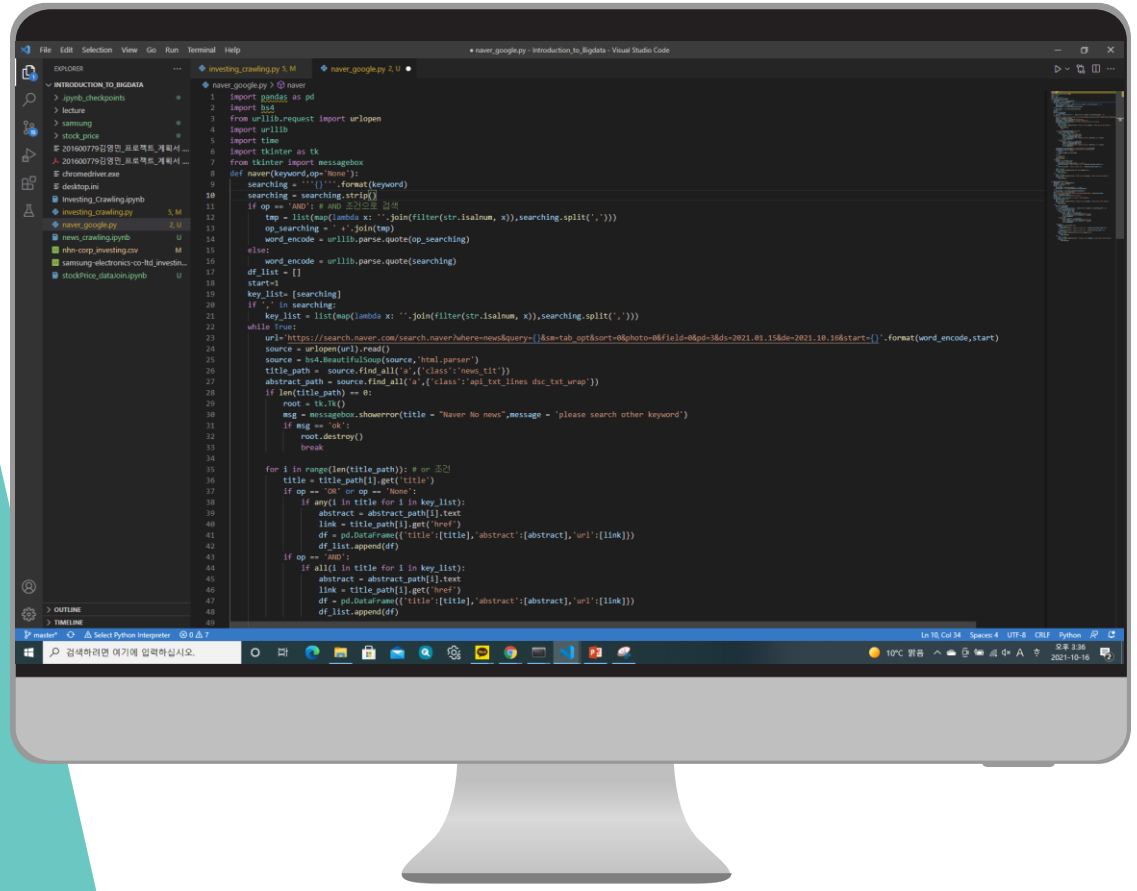

BeautifulSoup

BeautifulSoup를 사용하여 원하는 정보 추출

title	abstract	url	date	engine
"20일 삼성	삼성전자의	http://mon	2021.10.15	naver
"삼성전자	개미(개인	https://ww	2021.10.16	naver
떨어지는	주가, 연고	http://yna.	2021.10.14	naver
삼성전자가	조 바이든	http://new	2021.10.16	naver
삼성전자,	삼성전자는	http://www	2021.10.15	naver
삼성전자,	기사내용	http://www	2021.10.15	naver
삼성전자,	삼성전자는	http://www	2021.10.14	naver
[특징주]	삼성전자	http://yna.	2021.10.15	naver
삼성전자,	반도체 대	https://biz.	2021.10.15	naver
삼성전자	국내 코스	http://new	2021.10.15	naver
[특징주]	삼성전자	http://yna.	2021.10.15	naver
[속보] 삼	삼성전자	http://www	2021.10.15	naver
'7만전자'	삼성전자(	http://www	2021.10.15	naver
위기의 삼	최근 6만전	https://pre	2021.10.16	naver
반등장 개	최근 코스	https://vie	2021.10.15	naver
삼성전자 (	삼성전자 (	http://yna.	2021.10.14	naver
삼성전자,	기사내용	http://www	2021.10.12	naver
삼성전자	삼성전자(	http://www	2021.10.14	naver
올해만 5번	삼성전자가	https://ww	2021.10.16	naver
대장주 삼	코스피 시	https://ww	2021.10.15	naver
삼성전자,	목표가 연	http://www	2021.10.14	naver
"국민주 여	삼성전자의	http://new	2021.10.13	naver
삼성전자 '	삼성전자도	http://new	2021.10.15	naver
삼성전자,	삼성전자가	https://vie	2021.10.13	naver
삼성전자 !	기사내용	http://www	2021.10.12	naver
삼성전자,	삼성전자의	http://new	2021.10.15	naver
'동학개미	15일 오후	http://www	2021.10.15	naver
삼성전자 (	삼성전자가	http://www	2021.10.12	naver
미국발 훈	'6만전자(6	https://ww	2021.10.15	naver
코스피 30(	국내 증시	https://ww	2021.10.15	naver
'6만전자'	대장주 삼	http://www	2021.10.13	naver
코스피 3,0	2,900선으	https://imr	2021.10.15	naver
미워도 삼	코스피 시	https://ww	2021.10.15	naver
코스피 0.8	코스피 대	https://ww	2021.10.15	naver

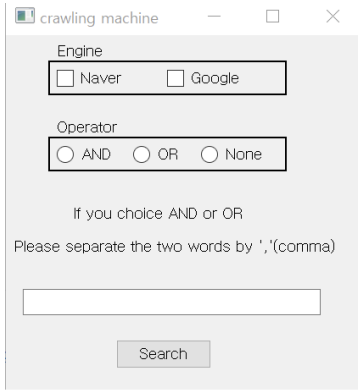

https://github.com/winston1214/project/tree/master/Keyword_Search_News_Crawling_Machine

Trouble Shooting

Trouble		Solution
각 종목에 대한 기사 일자가 한정됨 최대 3개월 남짓	Naver 증권의 기사 일자 제한	**네이버 검색으로 원하는 일자 기사 검색**
Urlopen 모듈 사용 제한 Header 값을 넣어도 사이트에 접속 불가	Investing.com의 urlopen 접속 불가	**Urlopen 접근이 아니라 Selenium으로 접근**
Selenium 사용 시 중간에 끊김 현상 발생 일정 개수가 넘어갈 때 데이터를 못받아오는 경우 발생	Investing.com 크롤링 제한	**time.sleep 이용과 불필요한 정보는 최대한 수집하지 않기**

Next Process

감정분석

Unsupervised-Learning

VADER
sentiwordnet

해당 회사에 대한 기사의 긍정부정 확률 반환

비지도 학습 기반 긍부정 예측

감정분석

Supervised-Learning

KoBERT

해당 회사에 대한 기사의 긍정부정 확률 반환

AI-HUB 데이터셋을 학습

지도 학습 기반 긍부정 예측

Prediction

ML or DL

LGBM, LSTM

해당 주가 상승 하락 예측

시계열 순서를 고려하지 않은 Classification

시계열 순서를 고려한 Classfication

THANK YOU